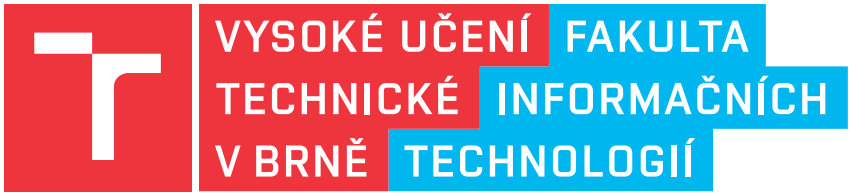

Projektová dokumentácia

Implementácia prekladača imperatívneho jazyka IFJ21

Tým 082, varianta II

8. decembra 2021

Andrei Shchapaniak	**(xshcha00)**	25 %
Andrej Bínovský	(xbinov00)	25 %
Zdenek Lapeš	(xlapes02)	25 %
Richard Gajdošík	(xgajdo33)	25 %

Obsah

1 Úvod

Cieľom projektu bolo vytvoriť funkčný prekladač napísaný v jazyku `C`, ktorý bude prekladať zdrojové kódy jazyka `Teal` do cielového jazyka `IFJcode21`, ktorý následne spracováva interpret. Program musí prijímať zdrojový program zo štandardného vstupu a vypisovať skompilovaný program na štandardný výstup.

2 Návrh a implementácia

2.1 Lexikálna analýza

`Scanner` slúži pre lexikálnu analýzu. Je implementovaný ako deterministický konečný automat, ktorý rozpoznáva všetky prichádzajúce tokeny. Uchováva informácie o tom či sa jedná o komentár, identifikátor, textové bloky, relačné operátory alebo iné validné, poprípade nevalidné tokeny u ktorých nastane lexikálna chyba 1. V prípade validného tokenu na základe koncového stavu sa vyplnia nasledujúce informácie v štruktúre `token_t`:

- `type` – typ načítaného tokenu
- `keyword` – keď typ je `T_KEYWORD`, do premennej `keyword` sa uloží odpovedajúca hodnota
- `attr.num_i` – číslo `integer`
- `attr.num_f` – číslo `double`
- `attr.id` – ostatné tokeny

V prípade že sa narazí na blok, ktorý označuje komentár je časť kódu ignorovaná a lexikálna analýza pokračuje až dalším tokenom mimo spomenutý blok.

2.2 Syntaktická analýza

Parser je hlavným modulom prekladača, protože komunikuje se všetkými ostatnými modulmi a riadi celú funkčnosť prekladača. Syntaktická analýza sa vykonáva zhora dolu metódou rekurzivného zostupu. Syntaktická analýza dostáva postupne od lexikálneho analyzátoru tokeny, ktoré následne musia spĺňať presnú syntaktickú štruktúru a postupnosť podla pravidiel `LL-gramatiky`. V prípade porušenia pravidla (typ prichádzajúceho tokenu se líší od očakávaného) sa vyhodí syntaktická chyba 2. V priebehu syntaktickej analýzy sú volané funkcie z modulu pre generovanie kódu, ktoré vygenerujú cielový kód z jazyka `Teal` do `IFJcode21`, ktorý nasledné spracováva interpret.

2.3 Spracovanie výrazov pomocou precedenčnej syntaktickej analýzy

Precedenčná syntaktická analýza je modul ktorý zaisťuje spracovanie výrazov metódou zdola hore. Vo svojom rozhraní obsahuje `expr()`, ktorú volá parser, keď chce precedenčnej analýze predať riadenie vo chvíli, kedy očakáva výraz.

2.3.1 Implementácia precedenčnej tabuľky

Postupne precedenčná analýza spracováva tokeny a pomocou precedenčnej tabuľky symbolov určuje precedenciu. Na základe tejto precedencie môže nastať päť stavov:

1. Pri precedencii `<` pridávame na zásobník načítaný token spolu so znakom precedencie.
2. Pri precedencii `>` redukujeme dva výrazy na jeden a ukladáme ich typ podľa pravidla.
3. Pri precedencii `=` zapíšeme načítaný znak z tokenu na zásobník.
4. Pri precedencii `e` sme narazili na nesprávne poradie znakov a nastáva sémantická chyba.
5. Pri precedencii `s` sme narazili na dva identifikátory alebo znak '`)`' a identifikátor. Následne redukujeme zvyšok výrazu a vraciame parseru riadenie.

2.4 Sémantická analýza

Sémantické chyby pre nekompatibilitu typu priradenia, návratových hodnôt a predaných argumentov do funkcií sa detekujú pomocou dvoch polí `tps_left` a `tps_right`. Po spracovaní určitého pravidla sa vykoná porovnanie podľa sémantiky jazyka `IFJ21`. Kompatibilita typu vo výraze sa detekuje tým istým spôsobom s rozdielom použitia dvoch premenných typu `char`. Sémantické chyby pre nedefiníciu, redefiníciu sa detekujú pomocou tabuliek symbolov. Globálna tabuľka symbolov je určená pre názvy funkcií. Pre názvy premenných je vytvorený zásobník tabuliek symbolov. Dôvodom implementácie zásobníka je riešenie problému s totožnými názvami premenných v rôznych rámcoch.

2.5 Generovanie cielového kódu

Generovanie cieľového kódu `IFJcode21` je implementovaný ako samostatný modul, ktorý je riadený syntaxou. Komponenty modulu sú volané v parseri na základe pravidiel `LL-gramatiky`. Z dôvodu neoptimalizácie sa cieľový kód generuje priamo bez tvorby trojadresného kódu.

2.5.1 Implementácia výpisu cieľového kódu

Na zaistenie výpisu cieľového kódu len za podmienky bezchybnej analýzy zapisujeme cieľový kód do dvoch textových blokov – definície funkcií a volanie funkcií. Tieto dva textové bloky po úspešnej analýze skonkatenujeme a vypíšeme na štandardný výstup.

2.5.2 Deklarácie premenných

Deklarácie premenných a ich možný konflikt názvov (na základe výskytu toho istého názvu v rôznych rámcoch) sme implementovali vďaka obojsmernému radu v ktorom sa ukladá adresa elementu tabuľky symbolov s príslušným identifikátorom. Element tabuľky obsahuje unikátne číslo premennej, ktorý zaisťuje jedinečnosť názvu premennej.

2.5.3 Funkcie

Volanie funkcií je zaistené vygenerovaním kódu, ktorý predá funkcii argumenty pomocou dočasného rámcu. Následne je vygenerovaný kód pre zavolanie funkcie. Pre správnu funkčnosť volanej funkcie je ihneď na začiatku generovaný kód, ktorý z dočasného rámca vytvori lokálny rámec funkcie a pre všetky argumenty ktoré boli funkcii predané vytvori promenné s názvami podľa parametrov funkcie. Následne sa generuje kód tela funkcie.

2.5.4 Výrazy

Generovanie kódu pre výraz sa začne vykonávať ihned po jeho redukcii. V priebehu redukcii je výraz zapísaný do obojstranného radu v postfixovom formáte. Jednotlivé elementy v rade nesú všetky potrebné informácie na generovanie výrazu - typ operátora, názov premennej či hodnotu konštanty. Generátor generuje len inštrukcie kódu `Ifjcode21` ktoré využívajú zásobník. To znamená že hodnoty, medzivýsledky a následne výsledok výrazu sú uložené na zásobník.

2.5.5 Podmienky a cykly

Pre generovanie podmienok a cyklov využívame náveštia, ktoré sú taktiež reprezentované unikátnym číslom a názvom funkcie kde sa nachádzajú. Na zabránenie redeklarácie premenných sa telo cyklu zapisuje do dvoch rôznych textových blokov. Vyskytnuté deklarácie zapisujeme naďalej do bloku definícií funkcií. No zvyšný kód tela cyklu zapisujeme do tretieho pomocného textového bloku. Následne po vygenerovaní celého cyklu tieto dva bloky skonkatenujeme.

2.6 Prekladový systém

2.6.1 CMake

`CMake` je multiplatformný nástroj na preklad zdrojových kódov. Nástroj sme vybrali na základe preferencií všetkých členov tímu. `CMake` nám predovšetkým pomáhal kompilovať a testovať výsledný program. Pravidlá pre preklad sú napísané v súbore `CMakeLists.txt` a po spustení nastroja `CMake` je automaticky vygenerovaný súbor `Makefile`. Na testovanie sme používali `google testy`, ktoré sme prekladali výhradne pomocou `CMaku`.

2.6.2 Skripty

Pre účely testovania boli vytvorené shellovské skripty. Jeden rozsiahly skript, ktorý uľahčoval a automatizoval testovanie všetkých častí projektu. Taktiež sme vytvorili skript pre preklad projektu a čistenie prebytočných súborov vzniknutých v dôsledku kompilácie projektu či testovacích súborov.

2.6.3 GNU Make

Zo zadania bolo požadované aby odovzdaný projekt obsahoval `Makefile`, ktorý s príkazom `make` preloží zdrojové súbory projektu a s príkazom `make clean` zmazal prebytočné súbory vzniknuté v dôsledku kompilácie. Tento nástroj nám taktiež pomáhal zabaliť celý projekt do jedného archívu `zip`.

3 Špeciálne algoritmy a dátové štruktúry

3.1 Tabuľka s rozptýlenými položkami

Túto dátovú štruktúru sme si zvolili vďaka časovej zložitosti (je reprezentovaná medzi `O(1)` až `O(n)`). Taktiež nám pomohli znalosti štruktúry z predmetov `IAL` a `IJC`. Veľkosť tabuľky jsme zvolili 101. Ako unikátny kľúč pre prístup k dátam v tabuľke slúži názov premennej alebo funkcie. Každý záznam v tabuľke obsahuje informácie o identifikátore. U premenných je uchovávaná aj informácia o hĺbke (redefinícia v zanorenejšom rámci kódu). Modul je implementovaný v súboroch `symtable.h` a `symtable.c`.

3.2 Pole rozptýlených tabuliek

Táto dátová štruktúra reprezentuje pole ktoré obsahuje tabuľky s rozptýlenými položkami. Každá tabuľka reprezentuje iný logický rámec. Modul je implementovaný v súboroch `symstack.c` a `symstack.h`

3.3 Obojsmerný rad

Obojsmerný rad je kombinácia zásobníka a radu. Je možné do neho vkladať aj odoberať dáta z oboch strán. Implementovali sme ho ako samostatný modul pre viac častí projektu. Je využívaný najmä v generovaní kódu, kde slúži na uchovávanie postfixového výrazu či identifikátorov. Taktiež obsahuje informáciách o parametroch, argumentoch a návratových hodnatách funkcií. Modul je implementovaný v súboroch `queue.c` a `queue.h`.

3.4 Obojsmerný zoznam

Táto dátová štruktúra je využitá pre spracovávanie výrazu v súbore `expressions.c`. Taktiež k štruktúre boli implementované funkcie pre jej obsluhu. Zložitosť je reprezentovaná ako `O(n)` pre vyhľadávanie a `O(1)` pre vkladanie na začiatok zoznamu.

3.5 Dynamický reťazec

Pre uchovanie vygenerovaného kódu počas prekladu a prácu s identifikátormi sme vytvorili štruktúru `string_t`. Pre obsluhu štruktúry sme vytvorili pomocné funkcie ako alokácia/dealokácia štruktúry, odstraňovanie, pridávanie a konkatenácia reťazcov. Modul je implementovaný v súboroch `str.c` a `str.h`.

4 Práca v týmu

Ihneď pri skladaní tímu sme si všetci uvedomovali, že sa očakáva pravidelná a skorá práca na projekte, čo sa nám nakoniec aj podarilo. Každý na projekte pracoval vždy s predstihom a darilo sa nam dodržiavať termíny, ktoré sme si stanovili.

4.0.1 Komunikácia a spôsob práce v tíme

Pre komunikáciu sme používali výhradne komunikačnú platformu `Discord`. Funguje na rovnakom princípe ako platforma `Slack`, ktorá sa používa profesionálne účely. Na danej platforme boli vytvorené komunikačné vlákna v ktorých boli založené `TODO` či `error` listy. Taktiež tam prebiehala bežná komunikácia či hlasové rozhovory s možnosťou zdieľania obrazovky, vďaka čomu sme mohli vyriešiť mnoho problémov digitálne a tým aj veľmi rýchlo. Avšak aj napriek dobrej digitálnej komunikácii sme sa snažili mať čo najviac osobných stretnutí.

4.0.2 Verzovací systém a vývojové prostredie

Ako vývojové prostredie sme využili `Clion` a `Vim`. Vývoj prebiehal na platformách `MacOs`, `Linux` a `Windows`. No testovanie prebiehalo len na operačnom systému `Linux`. Ako verzovací systém sme použili `git` spolu s portálom `GitHub`.

4.1 Rozdelenie práce medzi členmi tímu

Andrei:

- Lexikálna, sémantická a obecná syntaktická analýza
- Organizácia a kontrola práce nad projektom
- Tabuľka symbolov

Richard:

- Syntaktická a sémantická analýza pre výrazy
- Precedenčná tabuľka
- Prezentácia

Zdenek a Andrej:

- Generovanie kódu
- Automatizácia testovania
- Google testy, tvorba testov
- Dokumentácia

5 Záver

Projekt bol zadaný začiatkom semestra, ešte skôr, než boli prebraté všetky potrebné znalosti pre úspešné splnenie projektu . Boli sme si ale vedomí zložitosti a obsiahlosti projektu, a preto sme čerpali informácie aj zo záznamov prednášok z minulých rokov. To nám dalo potrebné informácie do štartu projektu a tým sme mohli začať s implementáciou s dostatočne veľkým predstihom. Už začiatkom semestra sme mali zostavený tím. Taktiež sme sa dohodli na komunikačných kanáloch a rozdelení práce. Takže s komunikáciou neboli žiadne problémy a každý vedel, čo sa od neho očakáva. Ak sme mali nejaké nejasnosti so zadaním, tak všetko sme si vyjasnili buď pomocou diskusného fóra alebo neoficiálneho komunikačného kanála študentov. V implementácii projektu sme používali sadu testov (vlastných aj zdieľaných s kolegami). Tieto testy nam veľmi dobre poslúžili na detekovanie chýb a urýchlenie práce nad projektom. Projekt bol pre nás veľmi prínosná skúsenosť. Priamo v praxi sme si objasnili veľa problémov ohľadom prekladačov a naučili sme sa ako fungujú. Zároveň sme ako tím zvládli pracovať veľmi pekným tempom. Tímová pomoc bola samozrejmosťou.

Diagram konečného automatu specifikujúceho lexikálny analyzátor

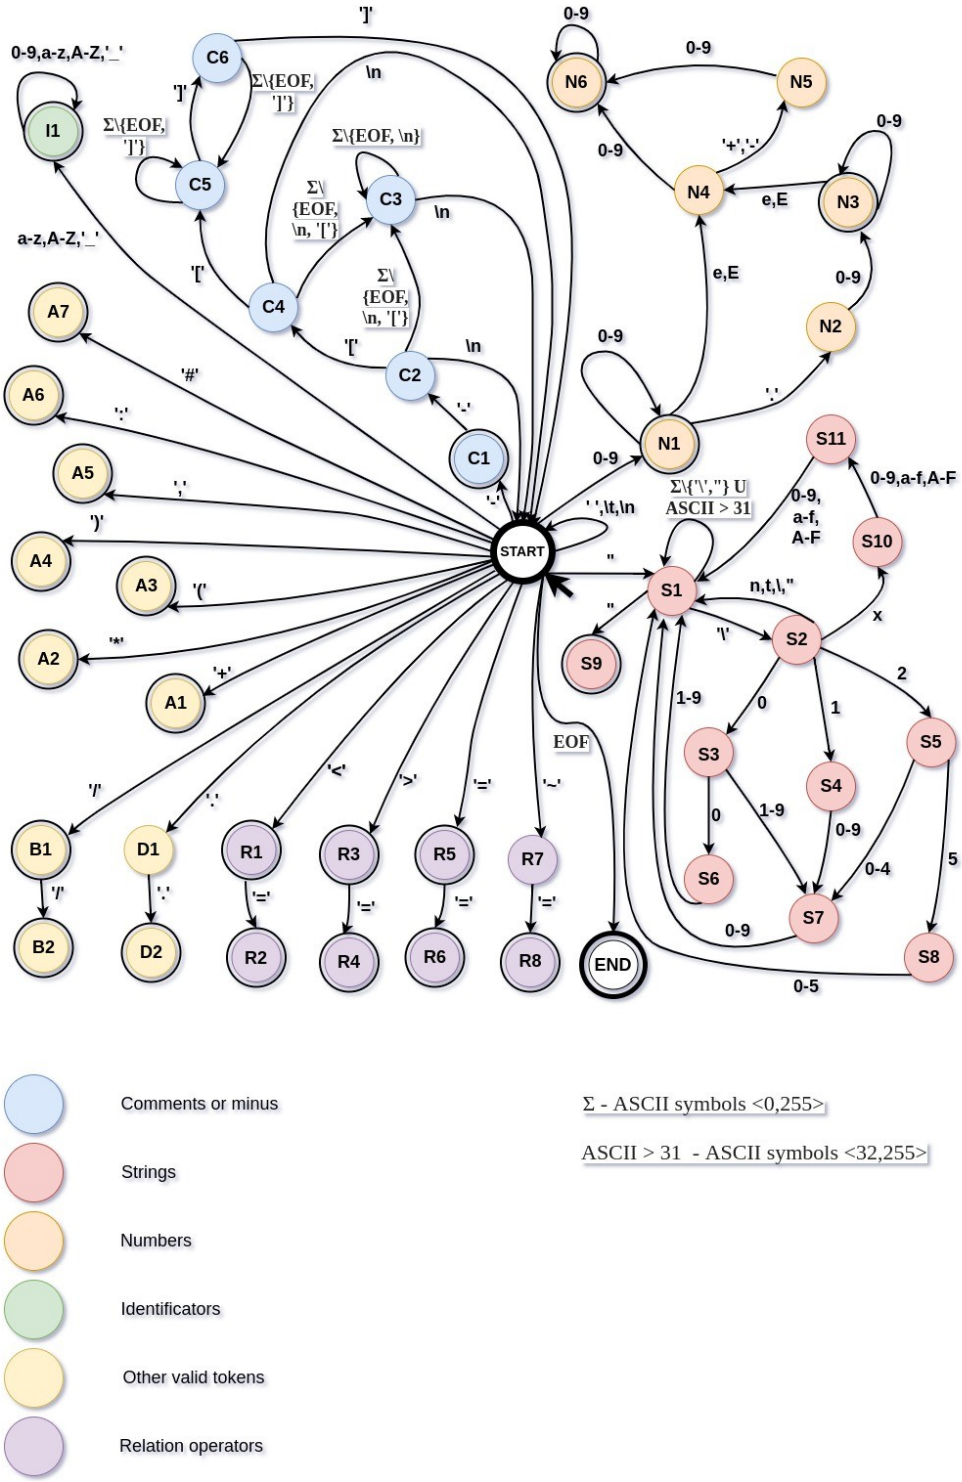

Obr. 1: Diagram konečného automatu špecifikujúceho lexikálny analyzátor

LL – gramatika

1. <prolog> → require t_string <prog>
2. <prog> → global id : function (<arg_T>) <ret_T> <prog>
3. <prog> → function id (<arg>) <ret_T> <stmt> end <prog>
4. <prog> → id (<param>) <prog>
5. <prog> → EOF
6. <arg_T> → <type> <next_arg_T>
7. <arg_T> → ε
8. <next_arg_T> → , <type> <next_arg_T>
9. <next_arg_T> → ε
10. <ret_T> → : <type> <next_ret_T>
11. <ret_T> → ε
12. <next_ret_T> → , <type> <next_ret_T>
13. <next_ret_T> → ε
14. <arg> → id : <type> <next_arg>
15. <arg> → ε
16. <next_arg> → , id : <type> <next_arg>
17. <next_arg> → ε
18. <type> → integer
19. <type> → number
20. <type> → string
21. <type> → nil
22. <stmt> → if <expr> then <stmt> else <stmt> end <stmt>
23. <stmt> → while <expr> do <stmt> end <stmt>
24. <stmt> → local id : <type> <def_var> <stmt>
25. <stmt> → return <expr> <next_expr> <stmt>
26. <stmt> → id <fork_id> <stmt>
27. <stmt> → ε
28. <def_var> → = <one_assign>
29. <def_var> → ε
30. <one_assign> → id (<param>)

31. <one_assign> → <expr>
32. <param> → <param_val> <next_param>
33. <param> → ε
34. <param_val> → `id`
35. <param_val> → <term>
36. <term> → `t_string`
37. <term> → `t_integer`
38. <term> → `t_number`
39. <term> → `nil`
40. <next_param> → `,` <param_val> <next_param>
41. <next_param> → ε
42. <next_expr> → `,` <expr> <next_expr>
43. <next_expr> → ε
44. <fork_id> → `(` <param> `)`
45. <fork_id> → <next_id>
46. <next_id> → `,` `id` <next_id>
47. <next_id> → `=` <mult_assign>
48. <mult_assign> → `id` `(` <param> `)`
49. <mult_assign> → <expr> <next_expr>

LL – tabuľka

	require	global	function	id	integer	string	number	nil	t_integer	t_number	t_string	if	while	local	return	:	=	(	,	EOF	$
<prolog>	1																				
<prog>		2	3	4																5	
<arg_T>					6	6	6	6													7
<next_arg_T>																			8		9
<ret_T>																10					11
<next_ret_T>																			12		13
<arg>				14																	15
<next_arg>																			16		17
<type>					18	20	19	21													
<stmt>				26								22	23	24	25						27
<def_var>																	28				29
<one_assign>				30																	31
<param>				32				32	32	32	32										33
<param_val>				34				35	35	35	35										
<term>								39	37	38	36										
<next_param>																			40		41
<next_expr>																			42		43
<fork_id>																	45	44	45		
<next_id>																	47		46		
<mult_assign>				48																	49

Precedenčná tabuľka

1. **E** → i
2. **E** → (**E**)
3. **E** → # **E**
4. **E** → **E** + **E**
5. **E** → **E** − **E**
6. **E** → **E** ∗ **E**
7. **E** → **E** / **E**
8. **E** → **E** // **E**
9. **E** → **E** .. **E**
10. **E** → **E** > **E**
11. **E** → **E** < **E**
12. **E** → **E** >= **E**
13. **E** → **E** <= **E**
14. **E** → **E** == **E**
15. **E** → **E** ~= **E**

	#	*	/	//	+	-	..	<	<=	>	>=	==	~=	(	)	i	$
#	<	>	>	>	>	>	>	>	>	>	>	>	>	<	>	<	>
*	<	>	>	>	>	>	>	>	>	>	>	>	>	<	>	<	>
/	<	>	>	>	>	>	>	>	>	>	>	>	>	<	>	<	>
//	<	>	>	>	>	>	>	>	>	>	>	>	>	<	>	<	>
+	<	<	<	<	>	>	>	>	>	>	>	>	>	<	>	<	>
-	<	<	<	<	>	>	>	>	>	>	>	>	>	<	>	<	>
..	<	<	<	<	<	<	<	>	>	>	>	>	>	<	>	<	>
<	<	<	<	<	<	<	<	>	>	>	>	>	>	<	>	<	>
<=	<	<	<	<	<	<	<	>	>	>	>	>	>	<	>	<	>
>	<	<	<	<	<	<	<	>	>	>	>	>	>	<	>	<	>
>=	<	<	<	<	<	<	<	>	>	>	>	>	>	<	>	<	>
==	<	<	<	<	<	<	<	>	>	>	>	>	>	<	>	<	>
~=	<	<	<	<	<	<	<	>	>	>	>	>	>	<	>	<	>
(	<	<	<	<	<	<	<	<	<	<	<	<	<	<	=	<	e
)	>	>	>	>	>	>	>	>	>	>	>	>	>	e	>	s	>
i	e	>	>	>	>	>	>	>	>	>	>	>	>	e	>	s	>
$	<	<	<	<	<	<	<	<	<	<	<	<	<	<	e	<	e

Legenda:

- `<` – Pridanie terminálu do zásobníka
- `>` – Redukcia
- `=` – Pridanie terminálu do zásobníka
- `e` – Chyba
- `s` – Špeciálny prípad – koniec výrazu